Universidad Nacional Autónoma de México

Facultad de estudios superiores Acatlán

División de ciencias socioeconómicas

Econometría 2

Modelo de Series de Tiempo SARIMAX para el Pronóstico de Precios Inmobiliarios (Casa de 3 Habitaciones) Mediante la Metodología Box-Jenkins

Integrantes:

- Hernández Pérez Luis Ángel
- López Ramírez Santiago
- Tapia Grimaldo María Fernanda
- Tapia Venegas Daniel Octavio

INTRODUCCIÓN

El análisis de series de tiempo permite estudiar la evolución de una variable a lo largo del tiempo y, a partir de su comportamiento pasado, generar pronósticos de su trayectoria futura. En el mercado inmobiliario esta herramienta es especialmente útil, ya que los precios de las viviendas presentan tendencias persistentes y una fuerte dependencia de su comportamiento reciente. El presente trabajo modela el precio medio de una casa de tres habitaciones mediante un modelo SARIMAX, con datos trimestrales de 2007 a 2019, y genera un pronóstico a ocho trimestres.

Para la construcción del modelo se siguió la metodología propuesta por George Box y Gwilym Jenkins (1970), un procedimiento iterativo que busca el modelo ARIMA más parsimonioso capaz de reproducir el comportamiento de una serie. Esta metodología se organiza en cuatro fases.

1. Identificación. El objetivo es determinar la estructura del modelo. Primero se verifica que la serie sea estacionaria, es decir, que su media, su varianza y su autocovarianza no dependan del tiempo. Si no lo es, se aplican transformaciones (como Box-Cox para estabilizar la varianza) y diferencias regulares o estacionales hasta lograrlo, lo que determina los parámetros d y D. Después se analizan las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie estacionaria para proponer los órdenes autorregresivos (p, P) y de media móvil (q, Q). En este trabajo, la serie requirió una diferencia regular y una estacional, y su estacionariedad se verificó con las pruebas de Dickey-Fuller aumentada (ADF) y KPSS.

2. Estimación. Una vez propuestos uno o varios modelos candidatos, se estiman sus parámetros, comúnmente por máxima verosimilitud, y se evalúa su significancia estadística. Los candidatos se comparan con criterios de información como el AIC y el BIC, que premian el ajuste y penalizan la complejidad. Aquí se compararon varias especificaciones, incluida la sugerida por `auto.arima`, y se seleccionó la de menor AIC. Como la serie presenta un episodio atípico en 2008-2009, se incorporó una variable exógena (*crisis*), lo que convierte el modelo en un SARIMAX.

3. Diagnóstico. Esta fase verifica que el modelo estimado sea adecuado. Si lo es, los residuos deben comportarse como ruido blanco: sin autocorrelación, con varianza constante y, idealmente, distribución

normal. Para comprobarlo se usan la prueba de Ljung-Box (autocorrelación), la prueba ARCH (heterocedasticidad condicional) y la de Jarque-Bera (normalidad), junto con el análisis gráfico de los residuos. Si el modelo no pasa el diagnóstico, se regresa a la fase de identificación para proponer una nueva especificación, de ahí el carácter iterativo de la metodología.

4. Pronóstico. Con un modelo validado se generan las predicciones para los periodos futuros, junto con sus intervalos de confianza, que reflejan la incertidumbre creciente conforme se amplía el horizonte. Cuando el modelo incluye variables exógenas, como en este caso, es necesario asignarles valores para el periodo pronosticado.

El resto del documento sigue esta estructura: primero se presentan la limpieza y el análisis exploratorio de los datos; después, la estacionariedad por diferenciación, la identificación del modelo mediante los correlogramas y las pruebas econométricas de diagnóstico; y finalmente el pronóstico y las conclusiones.

METODOLOGÍA

Limpieza y Análisis Exploratorio

Los datos provienen del archivo `ma_lga_12345.csv`, con 347 observaciones trimestrales y cuatro variables: fecha de venta (`saledate`), precio medio de venta (`MA`), tipo de propiedad (`type`) y número de habitaciones (`bedrooms`). Los montos se expresan en la unidad monetaria original de la base. El procesamiento se hizo en R con los paquetes `readr`, `janitor`, `dplyr` y `lubridate`. Primero se estandarizaron los nombres de las variables (`clean_names`) y se convirtió la fecha del formato dd/mm/aaaa a formato de fecha (`dmy`). Después, `type` se definió como factor (casa o departamento), `bedrooms` como entero y `ma` como numérica. Se eliminaron valores faltantes y registros duplicados, y se ordenó la base por tipo, habitaciones y fecha. El número de filas no cambió tras la limpieza (347), por lo que la base no tenía datos faltantes ni duplicados.

La base cubre del 31 de marzo de 2007 al 30 de septiembre de 2019 e incluye casas de 2 a 5 habitaciones y departamentos de 1 a 3. Para este trabajo se seleccionó la serie de **casas de 3 habitaciones**, con 51 observaciones, que se convirtió a un objeto de serie de tiempo trimestral (`ts`, frecuencia = 4) con inicio en el primer trimestre de 2007.

En el análisis exploratorio, la serie muestra una tendencia creciente: pasa de 421,291 en 2007 a 631,875 en el tercer trimestre de 2019 (Figura 1). Se distinguen tres etapas: un crecimiento sostenido de 2008 a 2011, una meseta alrededor de 506,000 entre 2011 y 2014, y una nueva fase de alza de 2014 a 2017 que se desacelera en 2018-2019. La recta de tendencia lineal superpuesta confirma que la media no es constante, lo que indica que la serie no es estacionaria en nivel.

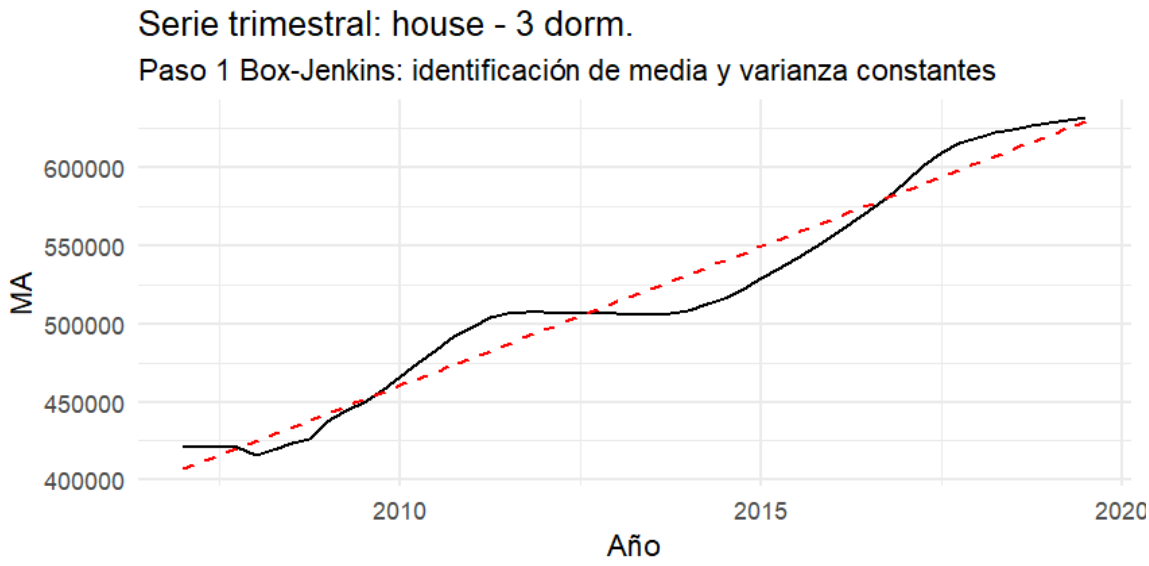


Figura 1. *Precio medio trimestral de casas de 3 habitaciones con recta de tendencia lineal, 2007-2019.*

Se aplicaron las descomposiciones multiplicativa (`decompose`) y STL (`stl`) para separar tendencia, estacionalidad y componente aleatorio (Figuras 2 y 3). El componente estacional resultó muy pequeño (de aproximadamente ±400 unidades monetarias, con un índice multiplicativo entre 0.9998 y 1.0002), y el componente aleatorio mostró sus mayores desviaciones en 2008-2009. Finalmente, se estimó el parámetro de la transformación Box-Cox con el método de Guerrero, que arrojó $\lambda = 0.949$. Al estar muy cerca de 1, no se justifica transformar la serie para estabilizar la varianza, por lo que se trabajó con la serie en niveles.

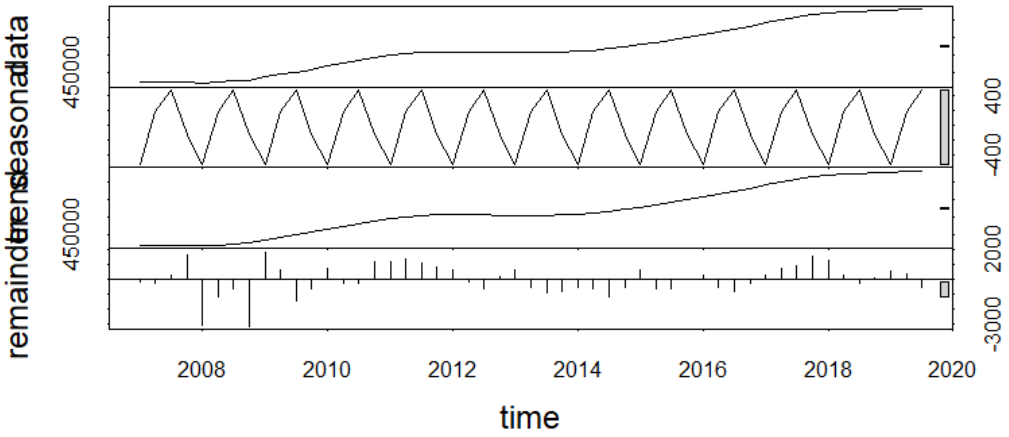


Figura 2. *Descomposición STL de la serie (datos, estacionalidad, tendencia y residuo).*

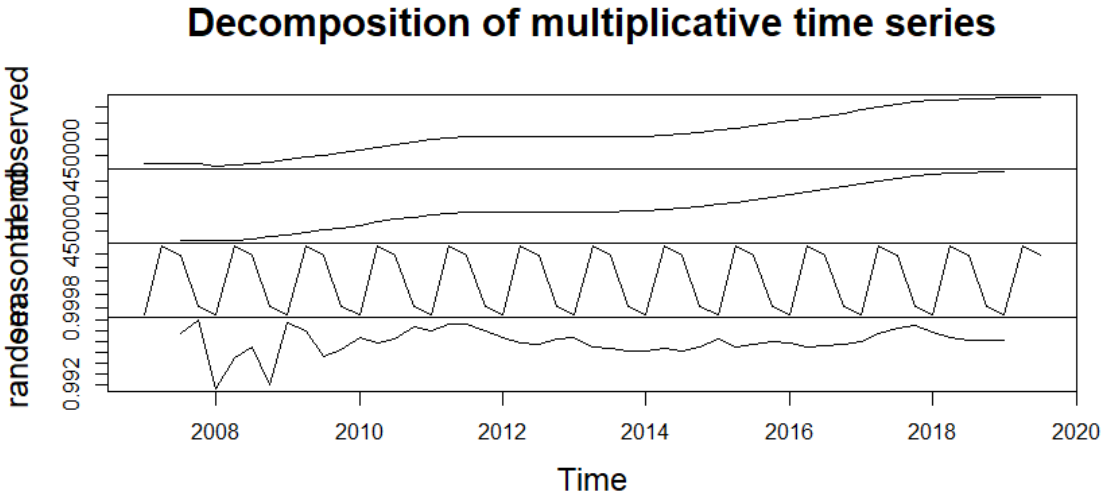


Figura 3. *Descomposición multiplicativa de la serie.*

Estacionariedad por diferenciación

Dado que la serie tiene tendencia, se aplicó una **primera diferencia regular (d = 1)**. La serie diferenciada ya no muestra tendencia, pero conserva ciclos largos y un pico cercano a 11,000 en 2009 (Figura 4). Se aplicó entonces una **diferencia estacional de rezago 4 (D = 1)** sobre la serie ya diferenciada, con lo que se obtuvo `dy_s`, una serie que oscila alrededor de cero sin tendencia visible (Figura 5). El valor atípico de 2009 persiste (cercano a 16,000) y coincide con el periodo de la crisis financiera.

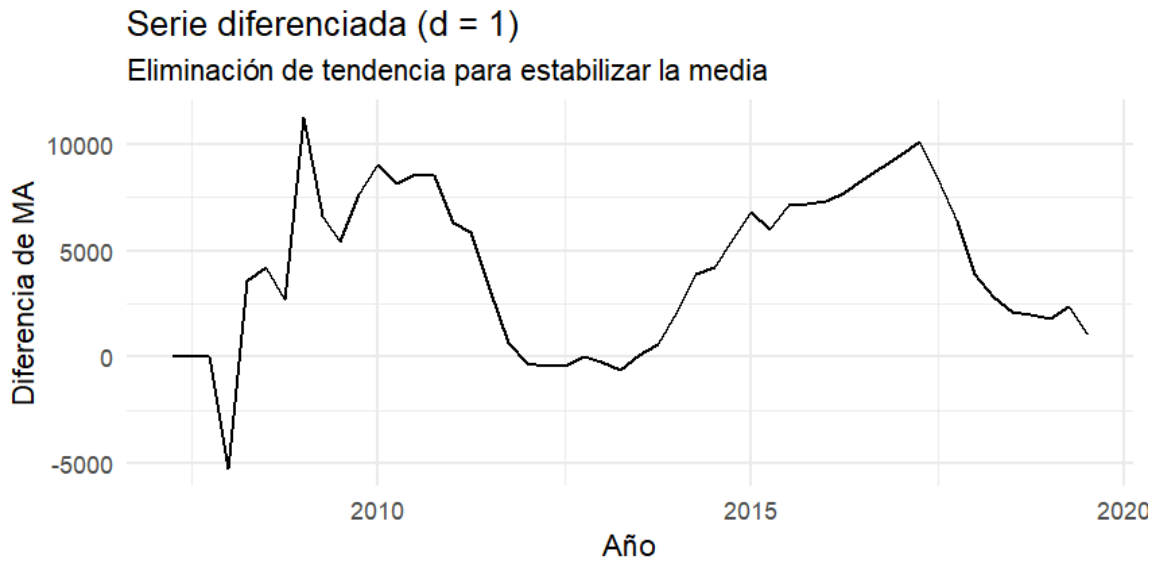


Figura 4. *Serie con una diferencia regular (d = 1).*

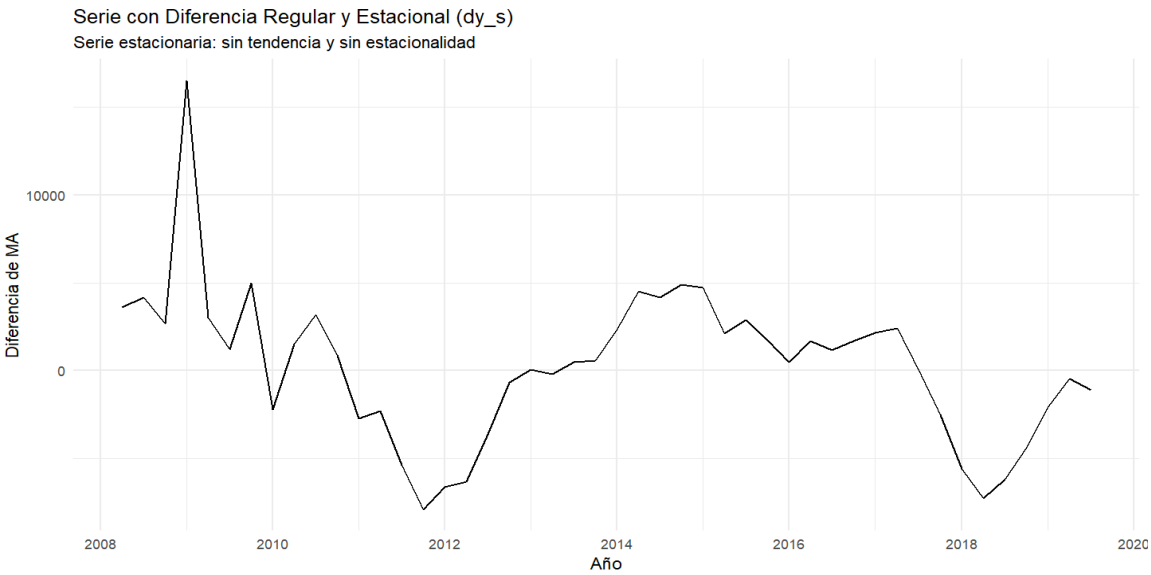


Figura 5. *Serie con diferencia regular y estacional (dy_s).*

La estacionariedad de `dy_s` se verificó con dos pruebas de raíz unitaria con hipótesis nulas opuestas (Tabla 1).

Tabla 1. *Pruebas de raíz unitaria sobre dy_s.*

Prueba	Ho	Estadístico	p-valor	Conclusión
ADF	Raíz unitaria (no estacionaria)	−4.163 (rezagos = 3)	0.0113	Se rechaza Ho: estacionaria
KPSS (nivel)	Estacionariedad	0.1996	> 0.10	No se rechaza Ho: estacionaria

Ambas pruebas coinciden en que la serie con una diferencia regular y una estacional es estacionaria.

Identificación del modelo mediante los correlogramas

Se analizaron el ACF y el PACF de `dy_s` hasta el rezago 24 (Figuras 6 y 7). El ACF decae lentamente, con correlaciones significativas en los primeros rezagos (alrededor de 0.65, 0.53 y 0.45 en los rezagos 1 a 3) y valores negativos en los rezagos 10 a 14. El PACF presenta un pico dominante en el rezago 1 (cercano a 0.65) y picos negativos significativos en los rezagos estacionales 4 y 8. Este patrón sugiere un componente **autorregresivo regular de orden 1** y un componente de **media móvil estacional de orden 1**, es decir, un SARIMA(1,1,0)(0,1,1)[4].

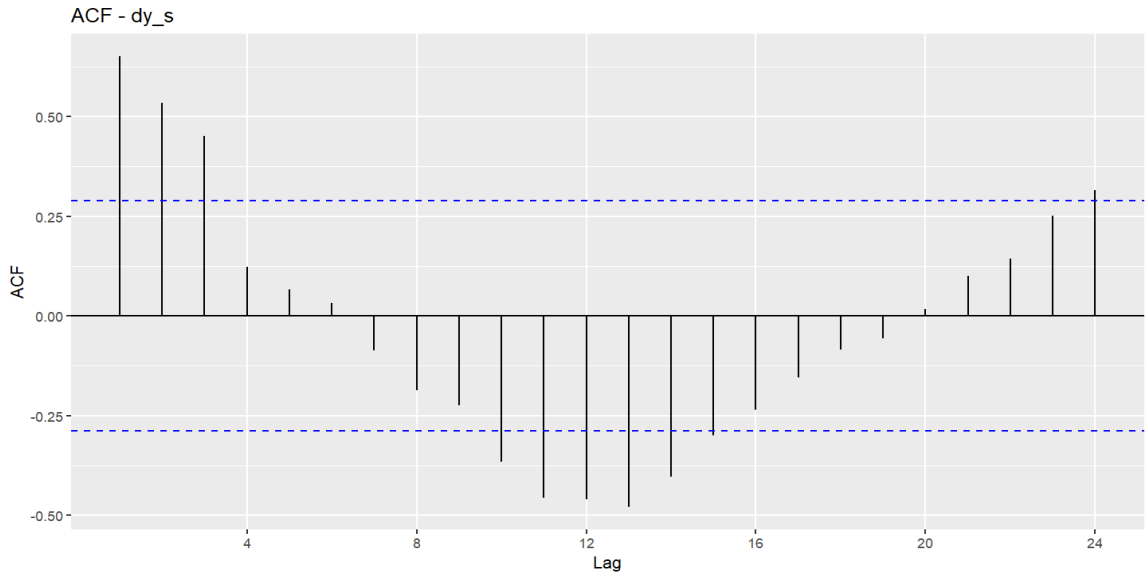


Figura 6. *Función de autocorrelación (ACF) de dy_s.*

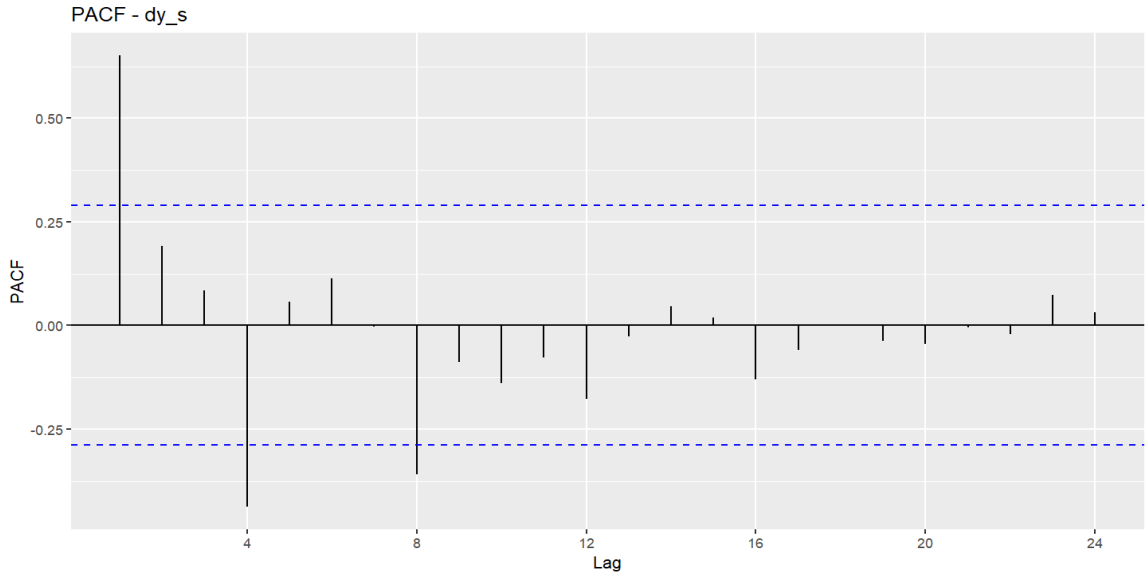


Figura 7. *Función de autocorrelación parcial (PACF) de dy_s.*

Para capturar el episodio atípico de 2008-2009 se construyó una variable dummy (*crisis*) que toma el valor 1 del tercer trimestre de 2008 al cuarto de 2009 y 0 en el resto, y se incluyó como regresor externo (`xreg`), lo que convierte el modelo en un SARIMAX.

Se estimaron cuatro modelos candidatos por máxima verosimilitud y se compararon con criterios de información (Tabla 2).

Tabla 2. *Modelos candidatos y criterios de información.*

Modelo	AIC	BIC
ARIMA(1,1,2)(2,1,0)[4] (`auto.arima`)	860.23	873.03
ARIMA(1,1,0)(0,1,1)[4]	**859.94**	**867.25**
ARIMA(1,1,1)(0,1,1)[4]	860.41	869.55
ARIMA(0,1,0)(0,1,1)[4]	902.17	907.66

Se seleccionó el ARIMA(1,1,0)(0,1,1)[4] por tener el menor AIC y el menor BIC, además de ser el más parsimonioso. Las diferencias con los dos primeros candidatos son pequeñas, mientras que el modelo sin componente autorregresivo es claramente inferior, lo que confirma la necesidad del término AR(1). Los coeficientes del modelo final se presentan en la Tabla 3.

Tabla 3. *Coeficientes estimados del modelo final.*

Parámetro	Estimación	Error estándar	p-valor
AR(1)	0.8307	0.0938	< 0.001
SMA(1)	−0.9999	0.1169	< 0.001

Parámetro	Estimación	Error estándar	p-valor
Crisis	−65.64	1,294.04	0.9595

Los parámetros AR(1) y SMA(1) son significativos. La variable *crisis* no resultó estadísticamente significativa, por lo que no se puede afirmar que su efecto sobre el nivel de la serie sea distinto de cero; esto se discute en las conclusiones.

Pruebas Econométricas (Jarque-Bera, ARCH, Ljung-Box)

Para validar el modelo se evaluó que los residuos se comporten como ruido blanco, tanto de forma gráfica (Figura 8) como con tres pruebas formales.

Ljung-Box (autocorrelación). H_0: los residuos no presentan autocorrelación. Con 8 rezagos y 2 grados de libertad descontados por los parámetros estimados, $Q^* = 7.732$ (6 g.l.) y $p = 0.258$. No se rechaza H_0: el modelo capturó la estructura de dependencia de la serie. El ACF de los residuos se mantiene dentro de las bandas de confianza, salvo el rezago 3, que las rebasa ligeramente; al tratarse de un solo rezago aislado y no rechazarse la prueba conjunta, no se considera relevante.

ARCH LM (heterocedasticidad condicional). H_0: no hay efectos ARCH. Con 4 rezagos, $\chi^2 = 2.018$ (4 g.l.) y $p = 0.732$. No se rechaza H_0: la varianza de los residuos puede considerarse constante en el tiempo y no se requiere un modelo de volatilidad.

Jarque-Bera (normalidad). H_0: los residuos siguen una distribución normal. Se obtuvo $\chi^2 = 401.97$ (2 g.l.) y $p < 2.2\times10^{-16}$, por lo que se rechaza H_0. El gráfico de residuos muestra la causa: un valor atípico positivo cercano a 11,000 en 2009, seguido de uno negativo de aproximadamente −5,500, que se reflejan como colas en el histograma. Fuera de ese episodio, los residuos se concentran en torno a cero. La no normalidad no invalida las estimaciones puntuales, pero implica que los intervalos de confianza del pronóstico, que asumen normalidad, deben interpretarse con cautela.

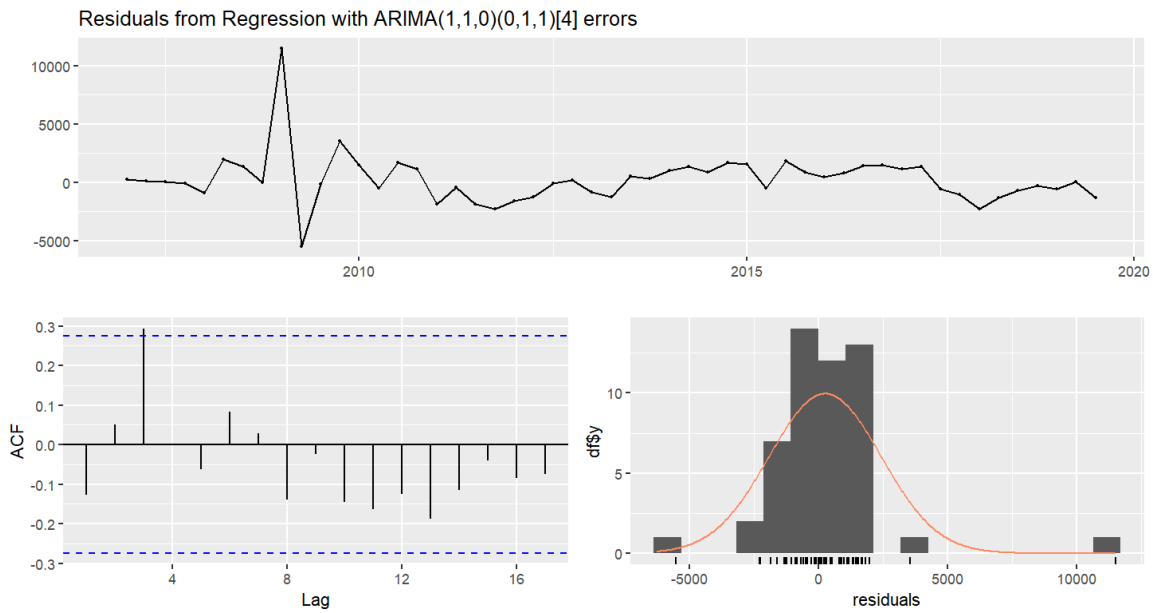


Figura 8. *Diagnóstico de residuos del modelo final: serie de residuos, ACF e histograma.*

Las medidas de ajuste dentro de la muestra fueron RMSE = 2,168.5, MAE = 1,315.7 y MAPE = 0.27%. En conjunto, el modelo cumple los supuestos de ausencia de autocorrelación y de heterocedasticidad condicional, y su principal debilidad es la no normalidad ligada al valor atípico de 2009.

PRONÓSTICO

Especificación y supuestos

Una vez validado el modelo mediante el diagnóstico de residuos, se utilizó el SARIMAX(1,1,0)(0,1,1)[4] para pronosticar el precio medio de una casa de tres habitaciones en un horizonte de ocho trimestres, es decir, dos años: del cuarto trimestre de 2019 al tercero de 2021. El modelo incorpora una variable exógena (*crisis*) que representa el choque de 2008-2009. Para generar el pronóstico es necesario asignar valores futuros a esta variable, y se fijó en cero para todo el horizonte. El supuesto es que el episodio de crisis ya no influye en la dinámica de los precios y que no se espera un choque similar en los próximos ocho trimestres.

Trayectoria esperada

El último valor observado de la serie, correspondiente al tercer trimestre de 2019, es de aproximadamente 632,000. A partir de ahí, el modelo proyecta una trayectoria creciente y suave, sin cambios bruscos, hasta alcanzar alrededor de 650,000 en el tercer trimestre de 2021 (Figura 9). Esto representa un aumento acumulado cercano al 3% en dos años, o un promedio aproximado de 0.4% por trimestre.

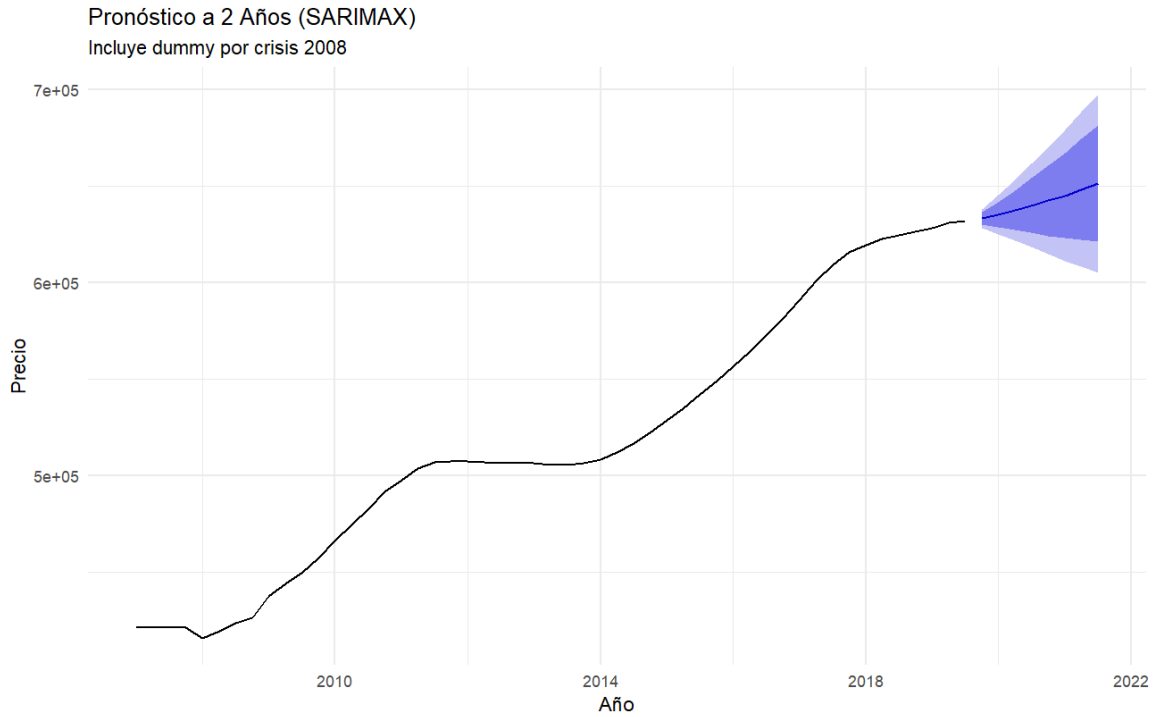


Figura 9. *Pronóstico a 8 trimestres con bandas de confianza al 80% y 95%.*

Este ritmo es considerablemente menor al observado entre 2014 y 2017, cuando la serie crecía entre 0.8% y 1.7% por trimestre. El pronóstico es coherente con la parte final de la muestra, donde el crecimiento ya se venía desacelerando: la serie pasó de aumentos trimestrales de entre 6,000 y 10,000 en 2017 a aumentos de entre 1,000 y 2,400 en 2019. En otras palabras, el modelo no extrapola la tendencia de largo plazo, sino que recoge la pérdida de impulso más reciente. Esto se explica por el componente autorregresivo (AR(1) = 0.83), que da peso importante al comportamiento inmediato anterior de la serie diferenciada.

Incertidumbre del pronóstico

Las bandas de confianza se ensanchan de manera sostenida conforme avanza el horizonte, lo cual es un rasgo esperado de los modelos con diferenciación, ya que el error de pronóstico se acumula con cada periodo. Al final del horizonte, el intervalo de 80% abarca aproximadamente de 620,000 a 680,000, y el de 95% de 605,000 a 697,000.

Esto tiene una implicación importante para la interpretación: aunque la media apunta a un alza moderada, los intervalos incluyen valores por debajo del último precio observado. Por lo tanto, el modelo sugiere una ligera tendencia al alza, pero no permite descartar un estancamiento o una caída en el precio durante el periodo. Además, como la prueba de Jarque-Bera rechazó la normalidad de los residuos (por el valor atípico de 2009), los intervalos, que se calculan bajo el supuesto de normalidad, deben tomarse como una referencia aproximada y no como una probabilidad exacta de cobertura.

Confiabilidad y alcance

La confiabilidad del pronóstico se apoya en tres elementos: los residuos no presentan autocorrelación (Ljung-Box, p = 0.258), no hay efectos ARCH (p = 0.732) y el error de ajuste dentro de la muestra es bajo (MAPE de 0.27%). Sin embargo, deben tenerse presentes dos matices. Primero, el error tan bajo se debe en parte a que la serie es muy suave, con poca variación entre trimestres, lo que facilita el ajuste. Segundo, no se realizó una validación fuera de muestra, por lo que no se puede cuantificar qué tan bien predice el modelo datos que no ha visto.

Por estas razones, el pronóstico es más confiable para el corto plazo (los primeros tres o cuatro trimestres, donde las bandas son más estrechas) que para el final del horizonte. Debe entenderse como un escenario base condicionado a que la dinámica reciente de los precios se mantenga, y

no como una predicción exacta. Factores externos como cambios en las tasas de interés, la oferta de vivienda o el entorno económico no están incluidos en el modelo y podrían alterar la trayectoria.

CONCLUSIONES

El modelo SARIMAX(1,1,0)(0,1,1)[4] describe adecuadamente la dinámica del precio medio de las casas de tres habitaciones entre 2007 y 2019. La serie requirió una diferencia regular y una estacional para ser estacionaria (ADF, $p = 0.011$; KPSS, $p > 0.10$); los correlogramas sugirieron un componente AR(1) y un SMA(1) estacional, y esa especificación obtuvo el menor AIC (859.94) y el menor BIC (867.25) entre los candidatos, con coeficientes AR(1) y SMA(1) significativos.

El diagnóstico de residuos es en general favorable: no hay autocorrelación (Ljung-Box, $p = 0.258$) ni efectos ARCH ($p = 0.732$), por lo que el modelo captura la estructura de dependencia y la varianza puede considerarse constante. Se rechazó la normalidad (Jarque-Bera, $p < 0.001$), pero la causa es casi por completo el valor atípico de 2009 y su rebote, y no un problema general de ajuste. Por ello, los intervalos de confianza deben leerse como aproximados.

El pronóstico a ocho trimestres indica que el precio medio seguirá una trayectoria creciente pero moderada: de unos 632,000 en el tercer trimestre de 2019 a alrededor de 650,000 en el tercero de 2021, un aumento cercano al 3% en dos años, muy por debajo del ritmo de 2014-2017 y en línea con la desaceleración de 2018-2019. Las bandas de confianza se abren con el horizonte e incluyen valores inferiores al último precio observado, de modo que el modelo respalda un escenario base de alza ligera, pero no descarta un estancamiento.

Limitaciones

Variable de crisis. La variable de intervención no fue significativa ($p = 0.96$), es decir, no mostró un efecto distinguible de cero. El valor atípico de 2009 es un choque puntual y no un cambio sostenido durante los seis trimestres que cubre la dummy, por lo que ésta lo diluye. Una alternativa natural es una dummy de pulso para el trimestre en que se concentra el residuo atípico.

Componente estacional. El coeficiente SMA(1) es prácticamente -1, lo que suele indicar sobrediferenciación estacional. La descomposición apunta en esa dirección, pues el componente estacional de la serie es mínimo. Conviene probar una especificación sin diferencia estacional ($D = 0$).

Capacidad predictiva. El error de ajuste dentro de la muestra (MAPE de 0.27%) es muy bajo, pero se debe en buena parte a que la serie es muy

suave y no equivale a capacidad predictiva. Al no haber validación fuera de muestra, la precisión real del pronóstico no está cuantificada.

Variables omitidas. El modelo solo usa la historia de la propia serie y la dummy de crisis; no incorpora factores como las tasas de interés, la oferta de vivienda o el ingreso de los hogares.

Líneas de mejora

Como extensión del trabajo se propone:

- Validar el modelo reservando los últimos ocho trimestres y calculando el error de pronóstico fuera de muestra ***(`window()` y `accuracy()`).***
- Reemplazar la *dummy* de varios trimestres por una de pulso.
- Comparar contra una especificación sin diferencia estacional.
- Incorporar regresores macroeconómicos en la parte exógena del modelo.

REFERENCIAS

Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5.ª ed.). Wiley.

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

ANEXO

R Script (Real Estate Data Time Series)

```
# ================================================================================
# 0. PAQUETES
# ================================================================================
# install.packages(c("readr", "tidyr", "dplyr", "lubridate", "janitor", "forecast",
#                    "tseries", "ggplot2", "patchwork", "FinTS", "lmtest"))
rm(list = ls())
library(readr)
library(janitor)
library(tidyr)
library(dplyr)
library(lubridate)
library(forecast)
library(ggplot2)
library(patchwork)
library(tseries)
library(FinTS)
library(lmtest)


# ================================================================================
# 1. CARGA Y VERIFICACIÓN DE LOS DATOS
# ================================================================================
# Ajustar la ruta a la ubicación local del archivo
ma_raw <- read_csv("ma_lga_12345.csv")

names(ma_raw)
dim(ma_raw)
head(ma_raw, 3)


# ================================================================================
# 2. LIMPIEZA DE LOS DATOS
# ================================================================================
ma_clean <- ma_raw %>%
  clean_names() %>%                                  # MA -> ma
  mutate(saledate = dmy(saledate)) %>%               # dd/mm/yyyy
  mutate(
    type     = factor(type, levels = c("house", "unit")),
    bedrooms = as.integer(bedrooms),
    ma       = as.numeric(ma)
  ) %>%
  drop_na(saledate, ma, type, bedrooms) %>%
  distinct() %>%
  distinct(saledate, type, bedrooms, .keep_all = TRUE) %>%
  arrange(type, bedrooms, saledate)

glimpse(ma_clean)
range(ma_clean$saledate)
table(ma_clean$type, ma_clean$bedrooms)


# ================================================================================
# 3. SELECCIÓN DE LA SERIE Y ANÁLISIS EXPLORATORIO
# ================================================================================
filtro_tipo <- "house"
filtro_dorm <- 3

serie_df <- ma_clean %>%
  filter(type == filtro_tipo, bedrooms == filtro_dorm) %>%
  arrange(saledate)
```

```r
# Serie trimestral (frecuencia = 4); start = (año, trimestre) de la primera observación
y <- ts(serie_df$ma,
        start = c(year(min(serie_df$saledate)),
                  quarter(min(serie_df$saledate))),
        frequency = 4)
y

# Descomposición multiplicativa y STL
desc <- decompose(y, type = "multiplicative")
plot(desc)
stl_fit <- stl(y, s.window = "periodic", robust = FALSE)
plot(stl_fit)

# Serie con recta de tendencia lineal
autoplot(y) +
  labs(
    title = paste("Serie trimestral:", filtro_tipo, "-", filtro_dorm, "dorm."),
    subtitle = "Paso 1 Box-Jenkins: identificación de media y varianza constantes",
    x = "Año", y = "MA"
  ) +
  geom_smooth(method = "lm", se = FALSE, linetype = "dashed",
              color = "red", linewidth = 0.7) +
  theme_minimal()

# Parámetro lambda de Box-Cox (alternativa: method = "loglik")
lambda_opt <- BoxCox.lambda(y, method = "guerrero")
lambda_opt

# ================================================================================
# 4. ESTACIONARIEDAD POR DIFERENCIACIÓN
# ================================================================================
# Primera diferencia regular (d = 1): elimina la tendencia
dy <- diff(y, differences = 1)
autoplot(dy) +
  labs(
    title = "Serie diferenciada (d = 1)",
    subtitle = "Eliminación de tendencia para estabilizar la media",
    x = "Año",
    y = "Diferencia de MA"
  ) +
  theme_minimal()

# Diferencia estacional (lag = 4, D = 1): elimina la estacionalidad
dy_s <- diff(dy, lag = 4)
autoplot(dy_s) +
  labs(
    title = "Serie con Diferencia Regular y Estacional (dy_s)",
    subtitle = "Serie estacionaria: sin tendencia y sin estacionalidad",
    x = "Año",
    y = "Diferencia de MA"
  ) +
  theme_minimal()

# Pruebas de raíz unitaria sobre dy_s
# H0 ADF: hay raíz unitaria (no estacionaria). Si p < 0.05 se rechaza H0.
adf.test(dy_s, alternative = "stationary")
# H0 KPSS: es estacionaria. Si p > 0.05 no se rechaza H0.
kpss.test(dy_s, null = "Level")

# ================================================================================
```

```r
# 5. IDENTIFICACIÓN: CORRELOGRAMAS
# ================================================================================
ggAcf(dy_s, lag.max = 24) + labs(title = "ACF - dy_s")
ggPacf(dy_s, lag.max = 24) + labs(title = "PACF - dy_s")

# ================================================================================
# 6. VARIABLE DE INTERVENCIÓN (CRISIS 2008-2009)
# ================================================================================
# En dy_s se observa un pico en 2008/2009. Se crea una dummy (1 en crisis, 0 en el resto).
# Con datos trimestrales, time(y) da valores como 2008.00, 2008.25, etc.
crisis_2008 <- ifelse(time(y) >= 2008.50 & time(y) <= 2009.75, 1, 0)
xreg_dummy <- matrix(crisis_2008, ncol = 1)
colnames(xreg_dummy) <- "crisis"

# ================================================================================
# 7. ESTIMACIÓN: MODELOS CANDIDATOS
# ================================================================================
# Candidato 1: selección automática
modelo_auto <- auto.arima(y, d = 1, D = 1, xreg = xreg_dummy,
                          stepwise = FALSE, approximation = FALSE)
summary(modelo_auto)

# Candidato 2: AR(1) regular y SMA(1) estacional (lo que sugieren los correlogramas)
mod1 <- Arima(y, order = c(1, 1, 0), seasonal = c(0, 1, 1), xreg = xreg_dummy)
# Candidato 3: ARMA(1,1) regular y SMA(1) estacional
mod2 <- Arima(y, order = c(1, 1, 1), seasonal = c(0, 1, 1), xreg = xreg_dummy)
# Candidato 4: solo SMA(1) estacional (sin parte regular)
mod3 <- Arima(y, order = c(0, 1, 0), seasonal = c(0, 1, 1), xreg = xreg_dummy)

# Comparación por criterios de información
cat("AIC mod1 (1,1,0)(0,1,1):", mod1$aic, "\n")
cat("AIC mod2 (1,1,1)(0,1,1):", mod2$aic, "\n")
cat("AIC mod3 (0,1,0)(0,1,1):", mod3$aic, "\n")
BIC(modelo_auto, mod1, mod2, mod3)

# ================================================================================
# 8. MODELO FINAL (mod1) Y DIAGNÓSTICO DE RESIDUOS
# ================================================================================
modelo_final <- mod1
summary(modelo_final)

# Diagnóstico visual (residuos, ACF e histograma) y prueba de Ljung-Box
checkresiduals(modelo_final)

residuos <- residuals(modelo_final)

# 8.1 Autocorrelación (Ljung-Box)
Box.test(residuos, lag = 8, type = "Ljung-Box", fitdf = 2)

# 8.2 Normalidad (Jarque-Bera)
jarque.bera.test(residuos)

# 8.3 Heterocedasticidad condicional (ARCH)
ArchTest(residuos, lags = 4)

# 8.4 Significancia de los coeficientes (pruebas z)
coeftest(modelo_final)

# ================================================================================
```

```r
# 9. PRONÓSTICO A 8 TRIMESTRES (2 AÑOS)
# ================================================================================
# La crisis ya pasó, así que la dummy futura es 0
futuro_xreg <- matrix(0, nrow = 8, ncol = 1)
colnames(futuro_xreg) <- "crisis"

pronostico <- forecast(modelo_final, h = 8, xreg = futuro_xreg)
print(pronostico)      # media e intervalos al 80% y 95%

autoplot(pronostico) +
  labs(title = "Pronóstico a 2 Años (SARIMAX)",
       subtitle = "Incluye dummy por crisis 2008", x = "Año", y = "Precio") +
  theme_minimal()
```